Agent面试题

1.什么是AI Agent？

2.什么是Harness？

3.Agent 的基本架构由哪些核心组件构成？

4. Workflow，Agent，Tools 这三个的概念和区别介绍一下？

5. 了解哪些 Agent 设计范式？

6. CoT是什么？ToT呢？

7. Agent 记忆压缩通常有哪些方法？

8. 在工程实践中，为什么有时候选择「手搓」Agent，而不是直接用成熟框架？

RAG面试题

1. 什么是 RAG？详细描述一个完整 RAG 系统的详细工作流程？

2. 大模型的 RAG 主要用来解决什么问题？

3. 微调和 RAG 各自的优劣势是什么？

4. 详细说说文档切割（Chunking）策略？

5. 在 RAG 中 Embedding 究竟是什么？如何选择和评估一个 Embedding 模型？

6. 什么是向量数据库？有没有做过向量数据库的对比选型？

7. 讲讲你用的向量数据库？数据量级是多大？性能如何？遇到过性能瓶颈吗？

8. 你使用 RAG 给大模型一个输入，系统是怎样的工作流程？

9. 如何润色用户的 Query（Query Rewrite）？目的是什么？

10. RAG 检索优化策略有哪些？

11. 了解哪些更复杂的 RAG 范式？

12. 如何规避 RAG 系统中大模型的幻觉？

13. 怎么量化你的 RAG 效果？

14. RAG 知识库如何实现动态与持续更新？

15. 在实际落地中，你觉得 RAG 最难的地方是哪里？

16. 不同来源的文档发生知识冲突时，RAG 应该信谁？

LLM工具调用面试题

1. 什么是 Function Calling？原理是什么？

2. LLM 是如何学会调用外部工具的？

3. 什么是 MCP（模型上下文协议）？讲讲它的核心

内容？

4. MCP 和 Function Calling 有什么区别？

5. Skill 是什么？

6. MCP 和 Agent Skill 的区别是什么？

7. 什么是 A2A 协议？

8. 说说 WebSocket 和 SSE 通信的区别及局限性？

9. 有没有用过大模型的网关框架？网关层解决了什么问题？

大模型工程面试题

1. 什么是大语言模型？

2. 讲讲 Transformer 架构基本原理？Encoder 和 Decoder 是什么？

3. 大模型是怎么训练出来的？

4. 什么是 Scaling Law？大模型的「涌现能力」是怎么回事？

5. 大模型微调的方案有哪些？

6. 大模型的参数：温度值、Top-P、Top-K 分别是什么？各个场景下的最佳设置是什么？

7. 大模型为什么会出现幻觉？怎么缓解？

8. 大模型部署有哪些主流方案？实际项目里怎么选？

9. 对比使用过哪些主流大模型？你们项目中最终选用了哪个模型？为什么？

10. 为什么长上下文会出现 Lost in the Middle？上下文窗口越大越好吗？

LangChain面试题

1. 你了解过哪些 AI Agent 开发框架？

2. 如何理解 LangChain 中的 Chain？

3. 在 LangChain 中，如何为 Agent 注册工具？

项目具体问题

1. 请你介绍一下 AI Agent 的记忆机制，并说说你的项目中是如何设计记忆模块的？

2. 什么是 Multi-Agent？你们项目中的muti-Agent是如何设计的？

3. 你们Agent项目的上下文工程怎么设计？

4. 你们Agent项目采用什么方案支持中断恢复？

5. 如何评测一个 Agent 的效果？

6. 线上 Agent 延迟明显升高时，如何通过 Trace 定位和优化？

7. Multi-Agent 系统如何处理子 Agent 超时、失联和并发修改冲突？

8. Agent 的「任务幻觉」是什么？如何避免没有执行工具却声称任务已经完成？

9. 大模型或 Agent 连接数据库时，如何防止越权、敏感数据泄漏和查询幻觉？

10. 工具很多时，Agent 如何减少 Token 并避免选错工具？

11. 工具调用格式非法、参数错误、超时或失败时，Agent 如何容错？

12. 使用 LangChain 构建 Agent 的核心步骤是什么？

13.你的Agent项目是如何做并行工具调用的？

14. 如何写好 Prompt？你们项目 Prompt 工程实践经验？

项目自主问答问题

请你介绍下支付智能助手项目，遇到过什么重难点？

请你介绍下HUB支付系统项目，遇到过什么重难点？

请你介绍下Agent开发学习平台项目，遇到过什么重难点？

请你介绍下薪福通项目，遇到过什么重难点？